Nicola Mastromarino

AI Engineer – GenAI / LLMOps / Cloud-Native

nickmastromarino54@gmail.com | LinkedIn | GitHub | Portfolio

1 Profilo Professionale

AI Engineer presso Machine Learning Reply, con background da Cloud Consultant in Nimbus Reply (Reply Group), specializzato in automazione cloud, DevSecOps e piattaforme enterprise. Laureando Magistrale in Computer Science (Curriculum AI) e diplomato Short Master in Generative AI (UniBa). Esperienza diretta su pipeline RAG (Hybrid/Graph), fine-tuning LLM (QLoRA) e deployment cloud-native production-ready con forte attenzione a governance e compliance.

2 Esperienza Professionale

- **AI Engineer** – *Machine Learning Reply* **Set 2026 – Presente**
  - Sviluppato la piattaforma GenAI per la generazione di video promozionali e brandizzati tramite orchestrazione di scene multimediali.
  - Progettato un AI Agent su LLM per l'analisi documentale e la compilazione automatica e strutturata delle schede progetto.
  - Gestito i requisiti architetturali e le checklist aziendali per il deployment e la compliance enterprise della soluzione web.
- **Cloud Consultant** – *Nimbus Reply* **Apr 2025 – Set 2026**
  - Automatizzati i workflow di provisioning tramite Python e Morpheus Data API, riducendo il carico operativo manuale del 70%.
  - Sviluppate pipeline di riconciliazione dati in Python tra vCenter, Morpheus CMP, ServiceNow e NSX in ambienti multi-cloud.
  - Gestiti Secret (Cyphers) e condotti audit RBAC su piattaforme multi-tenant con focus su sicurezza e conformità enterprise.
  - Progettate e ottimizzate pipeline CI/CD e processi DevSecOps per architetture cloud scalabili in ambienti regolamentati.
- **Graduate Research Intern** – *Università degli Studi di Bari* **Lug 2024 – Ott 2024**
  - Sviluppati modelli di Computer Vision per Facial Expression Recognition (FER) real-time su piattaforme di Social Robotics.
  - Applicata data augmentation e ottimizzazione deep learning (OpenCV, TensorFlow, PyTorch) mitigando bias algoritmici.

3 Istruzione

- **Laurea Magistrale in Computer Science** (Curriculum Artificial Intelligence) **2024 – In corso**
  Università degli Studi di Bari "Aldo Moro" – *Focus: Deep Learning, Computer Vision, NLP, Reinforcement Learning*
- **Short Master – Generative AI: dalla teoria alla pratica** **Dic 2025 – Apr 2026**
  Università degli Studi di Bari "Aldo Moro" – Direttore del Master: Prof. Marco Polignano
- **Laurea Triennale in Informatica** **2021 – 2024**
  Università degli Studi di Bari "Aldo Moro" – *Tesi: Sistemi di visione artificiale per FER su social robot*

4 Progetti Significativi

- **Medical RAG Question Answering System** (*Short Master Final Project*) **2026**
  - Pipeline RAG per Clinical QA su note MIMIC-III (∼40K note) con retriever ibrido (BM25 + S-PubMedBERT, RRF) e Adaptive Query Router.
  - Fine-tuning QLoRA di BioMistral-7B su 2× NVIDIA T4: allucinazioni ridotte del 40%, Token F1 +190% vs baseline.
  - Architettura conforme all'EU AI Act con supervisione Human-in-the-Loop (HITL). Stack: *FAISS, Hugging Face, Python.*
- **FactKG – Graph RAG su Knowledge Graph** (*Progetto NLP*) **2025**
  - Pipeline GraphRAG per fact-verification su 9.041 claim DBpedia con Llama-3 8B quantizzato a 4-bit (accuracy: 0.7350).

5 Certificazioni & Pubblicazioni

- **Google Cloud Certified Partner Specialist** – *Gemini Enterprise: Deployment & Agent Development* **Ott 2026 – Apr 2027**
- **Google Cloud Certified – Cloud Digital Leader** (*ID: 85b13cfa55e3447d8447dc8253865a57*) **Giu 2025 – Giu 2028**
- **Pubblicazione:** *L'Arte di Rallentare nell'Era dell'Iper-Velocità* (Lug 2026) – Saggio sull'impatto della GenAI su carico cognitivo e deep work.

6 Competenze Tecniche & Linguistiche

- **AI & GenAI:** RAG (Graph/Hybrid Retrieval, RRF), Fine-tuning (QLoRA), Model Evaluation, Prompt Engineering, Agentic Workflows
- **Framework & Librerie:** PyTorch, TensorFlow, scikit-learn, Hugging Face, FAISS, BM25, OpenCV
- **Cloud, DevOps & OS:** GCP, AWS, Docker, GitHub Actions, CI/CD, DevSecOps, Morpheus CMP, Linux, vCenter
- **Linguaggi & Metodologie:** Python, Java, C/C++, SQL, Bash | Architetture Microservizi, Design Patterns, Agile
- **Lingue:** Italiano (Madrelingua), Inglese (B1)

Appartengo alle categorie protette (Legge 68/1999). Autorizzo il trattamento dei dati personali ai sensi del GDPR (Regolamento UE 2016/679).