

Nicola Mastromarino

AI Engineer – GenAI / LLMOps / Cloud-Native
nickmastromarino54@gmail.com | LinkedIn | GitHub | Portfolio

1 Profilo Professionale

AI Engineer presso Machine Learning Reply, con background da Cloud Consultant in Nimbus Reply (Reply Group), specializzato in automazione cloud, DevSecOps e piattaforme enterprise. Laureando Magistrale in Computer Science (Curriculum AI) e diplomato Short Master in Generative AI (UniBa). Esperienza diretta su pipeline RAG (Hybrid/Graph), fine-tuning LLM (QLoRA) e deployment cloud-native production-ready con forte attenzione a governance e compliance.

2 Esperienza Professionale

- AI Engineer – Machine Learning Reply** **Set 2026 – Presente**
 - Sviluppata la piattaforma GenAI per la generazione di video promozionali e brandizzati tramite orchestrazione di scene multimediali.
 - Progettato un AI Agent su LLM per l'analisi documentale e la compilazione automatica e strutturata delle schede progetto.
 - Gestiti i requisiti architetturali e le checklist aziendali per il deployment e la compliance enterprise della soluzione web.
- Cloud Consultant – Nimbus Reply** **Apr 2025 – Set 2026**
 - Automatizzati i workflow di provisioning tramite Python e Morpheus Data API, riducendo il carico operativo manuale del 70%.
 - Sviluppate pipeline di riconciliazione dati in Python tra vCenter, Morpheus CMP, ServiceNow e NSX in ambienti multi-cloud.
 - Gestiti Secret (Cyphers) e condotti audit RBAC su piattaforme multi-tenant con focus su sicurezza e conformità enterprise.
 - Progettate e ottimizzate pipeline CI/CD e processi DevSecOps per architetture cloud scalabili in ambienti regolamentati.
- Graduate Research Intern – Università degli Studi di Bari** **Lug 2024 – Ott 2024**
 - Sviluppati modelli di Computer Vision per Facial Expression Recognition (FER) real-time su piattaforme di Social Robotics.
 - Applicata data augmentation e ottimizzazione deep learning (OpenCV, TensorFlow, PyTorch) mitigando bias algoritmici.

3 Istruzione

- Laurea Magistrale in Computer Science** (Curriculum Artificial Intelligence) **2024 – In corso**
Università degli Studi di Bari "Aldo Moro" – Focus: Deep Learning, Computer Vision, NLP, Reinforcement Learning
- Short Master – Generative AI: dalla teoria alla pratica** **Dic 2025 – Apr 2026**
Università degli Studi di Bari "Aldo Moro" – Direttore del Master: Prof. Marco Polignano
- Laurea Triennale in Informatica** **2021 – 2024**
Università degli Studi di Bari "Aldo Moro" – Tesi: Sistemi di visione artificiale per FER su social robot

4 Progetti Significativi

- Medical RAG Question Answering System** (Short Master Final Project) **2026**
 - Pipeline RAG per Clinical QA su note MIMIC-III (~40K note) con retriever ibrido (BM25 + S-PubMedBERT, RRF) e Adaptive Query Router.
 - Fine-tuning QLoRA di BioMistral-7B su 2x NVIDIA T4: allucinazioni ridotte del 40%, Token F1 +190% vs baseline.
 - Architettura conforme all'EU AI Act con supervisione Human-in-the-Loop (HITL). Stack: FAISS, Hugging Face, Python.
- FactKG – Graph RAG su Knowledge Graph** (Progetto NLP) **2025**
 - Pipeline GraphRAG per fact-verification su 9.041 claim DBpedia con Llama-3 8B quantizzato a 4-bit (accuracy: 0.7350).

5 Certificazioni & Pubblicazioni

- Google Cloud Certified – Cloud Digital Leader** (ID: 85b13cfa55e3447d8447dc8253865a57) **Giu 2025 – Giu 2028**
- AWS Educate – Introduction to Cloud 101 | Digital Transformation with GCP** **Apr 2025**
- Pubblicazione: L'Arte di Rallentare nell'Era dell'Iper-Velocità** (Lug 2026) – Saggio sull'impatto della GenAI su carico cognitivo e deep work.

6 Competenze Tecniche & Linguistiche

- AI & GenAI:** RAG (Graph/Hybrid Retrieval, RRF), Fine-tuning (QLoRA), Model Evaluation, Prompt Engineering, Agentic Workflows
- Framework & Librerie:** PyTorch, TensorFlow, scikit-learn, Hugging Face, FAISS, BM25, OpenCV
- Cloud, DevOps & OS:** GCP, AWS, Docker, GitHub Actions, CI/CD, DevSecOps, Morpheus CMP, Linux, vCenter
- Linguaggi & Metodologie:** Python, Java, C/C++, SQL, Bash | Architetture Microservizi, Design Patterns, Agile
- Lingue:** Italiano (Madrelingua), Inglese (B1)